

Zaawansowane Zagadnienia Sieci Neuronowych

Dokumentacja Wstępna Projektu

Michał Kopeć 311311

Kacper Klasa 310742

1. Temat projektu

Przygotuj implementację metody uczącej ADOPT.

W przypadku implementacji własnej, należy ją zrealizować w ramach bazowej klasy optymalizatora w wybranym frameworku (PyTorch, TensorFlow itd.). Taką implementację należy następnie porównać z dwoma dostępnymi w wybranym frameworku metodami uczącymi na dwóch różnych zadaniach, dobierając wartości hiperparametrów wybranych metod.

W przypadku wykorzystania gotowej implementacji wskazanej w temacie metody, należy ją porównać z czterema dostępnymi w wybranym frameworku metodami uczącymi na czterech różnych zadaniach, dobierając wartości hiperparametrów wybranych metod.

Zadania do porównania powinny pochodzić z artykułów opisujących metodę implementowaną lub metod wybranych do porównania.

2. Wybrany sposób rozwiązania

Zdecydowaliśmy się na wykorzystanie gotowej, oficjalnej implementacji w PyTorch dostępnej na [GitHub](#) i porównanie jej z czterema wybranymi metodami uczącymi na czterech zadaniach uczenia głębokiego wymienionych poniżej.

3. Wybrane metody uczące

Adam - jest to najpopularniejsza metoda ucząca i główny punkt odniesienia autorów metody ADOPT.

AdamW - metoda rozszerzająca Adam o regularyzację *decoupled weight decay*.

SGD (wersja z momentum) - prosty i powszechny algorytm, chociaż często wolniejszy niż metody adaptacyjne zazwyczaj prowadzi do bardzo dobrej generalizacji modeli.

RMSProp - adaptacyjny algorytm podobny do Adam, ale bez estymacji momentu pierwszego rzędu.

4. Wybrane problemy

- Klasyfikacja obrazów na zbiorze danych [CIFAR-100](#).
- Fine-tuning modelu DistilBERT do zadania klasyfikacji sentymentu na zbiorze danych [IMDB](#).
- Generacja obrazów na zbiorze [TissueMNIST](#).
- Zadanie regresji na wybranym zbiorze danych o średniej/wysokiej złożoności.

5. Metodyka porównania

Strojenie hiperparametrów

Przed uwzględnieniem w finalnym porównaniu, dla każdej metody uczącej w każdym zadaniu zostanie przeprowadzone strojenie hiperparametrów (*learning rate* i opcjonalnie innych parametrów metody) z wykorzystaniem biblioteki Optuna, służącej do efektywnego wyszukiwania najlepszych wartości hiperparametrów.

Dodatkowo wykorzystane do eksperymentów zostaną domyślne wartości hiperparametrów dostarczane wraz z każdą z metod uczących.

Kryteria porównania metod uczących

Porównanie metod uczących będzie podzielone na dwie części:

Zachowanie podczas treningu - analiza, jak dobrze dana metoda ucząca optymalizuje funkcję straty poprzez porównanie wartości funkcji straty w różnych momentach treningu oraz szybkości osiągnięcia zadanego dla konkretnego zadania progu jakości.

Generalizacja modelu - porównanie jakości wytrenowanego modelu na zbiorze testowym.

Przebieg eksperymentów dla jednego zadania

1. Zdefiniowanie architektury modelu.
2. Podział zbioru danych na treningowy, walidacyjny i testowy.
3. Optymalizacja hiperparametrów dla każdej z metod uczących na podstawie wyników na zbiorze walidacyjnym.
4. Ustalenie liczby epok i progu jakości dla danego zadania.
5. Przeprowadzenie pełnego treningu przy wykorzystaniu każdej z metod uczących z domyślnymi i dostrojonymi hiperparametrami. Zapisywanie wszystkich istotnych metryk, jak wartość funkcji straty w każdej iteracji/epoce oraz jakość na zbiorze walidacyjnym po zakończeniu każdej epoki.
6. Zapisanie wyników na zbiorze testowym osiągniętych przez wytrenowany model.
7. Porównanie zachowania podczas treningu oraz otrzymanych wyników na zbiorze testowym.

Przy 4 zadaniach i 5 metodach uczących porównywanych na wersjach z dostrojonymi oraz domyślnymi parametrami w porównaniu zostanie uwzględnione $4 * 5 * 2 = 40$ eksperymentów.